

期待利益最大化に向けた分析レポート (観察データ・オフポリシー評価・制約付き配 信・実験計画)

川嶋宥翔

分析の再現: `analytics/・run_analysis.py`

May 2, 2026

Abstract

目的. 店舗顧客の観察データに対し、購入（コンバージョン）予測、多値介入に対する傾向スコアと二重頑健（doubly robust; DR）推定量、 K 折アウト・オブ・フォールド（OOF）予測に基づくオフポリシー評価、期待利益最大化に基づく離散政策、および接触上限等の制約下での貪欲割当を一連のパイプラインとして整理する。

識別と限界. 推定の解釈は条件付き無視可能性 $Y(t) \perp T \mid X$ 、SUTVA、共通支援の下での参考値に留まる。未観測交絡があれば DR も漸近的にバイアスを残す。増分効果の確定にはランダム化比較試験（RCT）を要する。

価値とコスト. 会計上の粗利・LTV は本データに含まれないため、history を円建ての売上 proxy とみなし、`analytics/config.py` に定義したコストシナリオによる感度分析のみを行う（絶対額の断定はしない）。

推論. ブートストラップ区間は訓練データの層化部分標本再学習に基づく。全件ノンパラメトリック・ブートストラップによる区間とは一般に一致しない。

最終課題との対応（要旨）. 課題は「コンバージョン確度の高い顧客の傾向の把握」と「プロモーションの対象設計」である。本稿では購入確率の予測と処置別の参考推定を踏まえ、購入確度が高いからといって高コストインセンティブを配るのが最適とは限らない点（期待利益・コスト・観察データの限界）を数値で示す。誰に・何を・どの KPI で評価するかは第 2 節に集約する。

経営者向け要約（1 ページ）

会議・口頭説明用に、結論だけを先に示す（詳細は本文）。

- ・ **推奨ターゲット（スコア層）:** 購入確率モデル（ロジスティック）でランキングし、上位 5~10% を優先候補とする。ホールドアウト上で当該層の実測 CVR は約 27-28%（全体ベースライン約 14.7%、`artifacts/topk_precision_recall_logreg.csv`）。

- **推奨オファー／チャンネル（オフライン・参考）**：期待利益の代理指標では、No Offer / Web（インセンティブを掛けない・Web 接触）が最頻となるシナリオが多い。条件付き CVR が高く見える割引系も、コストを差し引くと利益では劣後しうる（本文 policy_reco_dist 等）。コスト係数の感度は表 6：割引コストを極端に下げた設定では Discount / Web が最頻になりうる一方、高コスト設定では No Offer / Web が支配的となり、推奨処置が入れ替わる。なお本データにはメッセージ文面・接触頻度・配信タイミングが無く、施策はオファー × チャンネルの離散処置として評価している（第 2 節）。
- **次のパイロット（仮説・規模・成功指標）**：
 - **仮説**：スコア上位層では、軽い訴求（無オファー・低コストチャンネル）でも、重い割引と購入率・利益 proxy で大差がつかない（または割引の増分が小さい）。
 - **母数の目安**：購入率差 MDE 1pt・検定力 0.8 なら片群約 2.0 万・合計約 4.0 万（表 7）。上位 10% だけを母集団に絞る設計なら、必要人数は再見積もり。
 - **成功指標**：購入率（主アウトカム）、期待利益 proxy（history を円の売上 proxy とみなす）、接触コスト、副次として試験後 90 日累積売上（LTV proxy）と 90 日以内再購入を事前登録。運用面では校正（Brier/ECE）・傾向 ESS の閾値内維持（本編の閾値例参照）。

Contents

1 序論	5
1.1 分析の目的と背景（最終課題との対応）	5
1.2 使用データの概要	5
1.3 データ生成過程に関する仮説（割当のストーリー）	6
1.4 課題に対する結果の要約（先読み）	6
1.5 本稿の構成と優先順位（データ・手法・結果）	7
1.6 本稿の貢献（分析パイプラインとしての位置づけ）	7
1.7 記号とデータ生成	8
1.8 図表の見方と再現性	8
1.9 本編と付録の読み方（役割分担）	8
2 推奨ターゲットの定義と評価 KPI	8
3 問題設定と識別仮定	10
3.1 潜在的結果とターゲット	10
3.2 識別条件	10
3.3 補足：購入しやすさの予測と「増分効果」の違い	10
4 データと探索（分布・条件付き CVR）	10
4.1 周辺分布と層別箱ひげ	11
4.2 オファー × チャンネル別の条件付き CVR	13
4.3 属性別 CVR（棒グラフ）	13

5 多重検定（FDR）と効果量	15
5.1 方法	15
6 相関と補助的重回帰（history）	16
6.1 Pearson 相関（数値・二値）	16
6.2 OLS（目的変数を history）	16
7 LSI 類似表現と分類アブレーション	16
8 予測モデル（ROC・校正・PR）	18
8.1 評価指標の意味	18
9 因果推論（傾向スコア、DR、ブートストラップ）	22
9.1 DR 推定量（参考）	22
9.2 実装上の注意（同一データ学習）	22
9.3 層別の観察差と「無駄割引」仮説への接続（参考）	24
10 期待利益・オフポリシー評価・ベンチマーク	24
10.1 期待利益の定義（オフライン代理）	24
10.2 オフポリシー評価の読み方	25
10.3 制約付き配信（食欲近似）	27
11 セグメントと頑健性	29
11.1 潜在空間の可視化	29
11.2 セグメント × 処置の観測 CVR（探索）	32
12 実験計画（RCT/A/B）	32
13 ガバナンス・倫理・人の関与	34
14 運用モニタリングとインシデント対応	34
15 まとめと今後の方針	35
15.1 最終課題の再確認	35
15.2 分析結果の要約	35
15.3 想定や直感と異なる結果とその理由	36
15.4 今後の方針（新施策の提案）	36
15.5 上位スコア層を母集団としたパイロットの記述（演習データ）	36
15.6 追加で欲しいデータ（次の分析のため）	37
15.7 本稿の位置づけ（ロードマップ）	38
15.8 最終課題への適合性と改善余地（自己査読）	39
A 限界と免責	40
B 付録：データスニペットの再現方法	40

C 付録：コスト感度表の再現方法	40
D 付録：本文で詳述しきれなかった出力物	40
E 付録：仮定データによる補完分析（図表・サンプル・コード）	41
E.1 仮定パラメータ（JSON）	41
E.2 データセット抜粋（演習用 <code>exercise.csv</code> ）	41
E.3 合成露出ログ抜粋	47
E.4 分析に用いた Python コード	47

1 序論

1.1 分析の目的と背景（最終課題との対応）

店舗顧客の購買・接触データを用い、誰にどのプロモーション（オファー × チャンネル）を送るとよいかを検討する。本稿でのプロモーション／接触政策は、割引・BOGO等のインセンティブだけでなく、オファー無し（No Offer）やチャンネル選択も含むものとする（課題データ上の offer の取りうる値に対応）。

課題文では「コンバージョン確度の高いユーザーにプロモを打つ」という方針が示されるが、実務では（i）そもそも購入しそうな顧客への割引は無駄になりやすい（増分性の問題）、（ii）チャンネル・オファーにはコストが伴う、（iii）観察データでは処置が交絡しうる、の三点が同時に立ちはだかる。本稿の目的は、上記を踏まえたうえで、記述統計 → 購入予測 → 処置効果の参考推定（DR） → 期待利益に基づく離散政策 → 制約・実験・ガバナンスという順に、意思決定に使える優先度の高い証拠から積み上げることである。

マーケティング施策は（オファー種別 × チャンネル）など多値の離散介入として観察される。本稿では、施策の記述的関連（条件付き CVR）から出発し、購入確率の予測モデル、介入割当の傾向モデルと結果モデルを用いた DR 推定、そして期待利益に基づく個別最適化政策へと分析を段階的に接続する。各段階で必要な統計的仮定と実装上の近似（同一データ再使用、貪欲制約解など）を明示する。

1.2 使用データの概要

観測件数は 64,000 行、全体 CVR（conversion=1 の割合）は 0.1468 である。主要な列は次のとおり。

- recency：最終購入からの経過（月）。
- history：過去購入金額の proxy（本レポートでは円建ての連続値として解釈する）。
- used_discount, used_bogo：過去の割引・BOGO 利用（0/1）。
- zip_code：居住地域カテゴリ（Urban / Rural / Surburban）。注：Surburban はデータファイル上の綴りであり、意味は「郊外」相当（課題説明では Suburban と書かれることがある）。
- is_referral：紹介流入フラグ（0/1）。
- channel：接触チャンネル（Web / Phone / Multichannel）。
- offer：提示オファー（Discount / Buy One Get One / No Offer）。
- conversion：購入有無（0/1）。

Table 1: 分析データの例 (exercise.csv から抜粋。説明用の代表行)

recency	history	disc	bogo	zip	ref	channel	offer	conv
6	134.83	0	1	Suburban	0	Phone	Buy One Get One	1
7	548.91	0	1	Urban	1	Phone	Buy One Get One	1
10	142.44	1	0	Suburban	0	Phone	Buy One Get One	0
6	329.08	1	1	Rural	1	Web	No Offer	0
2	3345.93	1	1	Suburban	1	Phone	No Offer	0
1	211.45	0	1	Urban	1	Phone	Buy One Get One	0

通貨単位の扱い. 課題データの `history` はファイル上は無次元の数値だが、本稿では円 (JPY) として一貫して解釈する。期待利益の proxy・付録のフェルミ仮定・図表の金額軸は、特記なき限り同じく円を意味する。

データに含まれないこと (割当・運用). 各行は顧客の属性・観察されたオファー・チャンネル・購入有無を示すが、なぜその顧客にその `offer` が割り当てられたかという運用ルール・優先順位・在庫・キャンペーン枠は観察されない。したがって本稿の処置比較・政策シミュレーションは観察研究としての参考値であり、現場の割当ロジックをそのまま特定できるわけではない。

1.3 データ生成過程に関する仮説 (割当のストーリー)

本データ単体では `offer` の割当アルゴリズムは特定できないが、小売・CRM の典型的運用に照らし、次のような仮説的メカニズムを置いておくことで観察研究としての読み方が定まる (検証は別途ログ監査・実験が必要)。

- ・ **休眠・低エンゲージ層** に強いインセンティブ (割引・BOGO) を振り向け、**直近に購入がある層** には無オファーまたは軽い訴求に留めるルールベース配信。
- ・ **チャンネルコスト** (DM・電話・マルチ) に応じて、LTV や反応履歴で上位顧客にのみ高コスト接触を許可する **優先度キュー**。
- ・ **キャンペーン枠・在庫・クレジット枠** により、同一セグメント内でも **実際に観察されるオファーが制約される** (未観測の配分制約)。

このストーリーが正しければ、条件付き CVR の高さは **処置効果** ではなく **割当規則と母集団の交絡** で説明される部分が多い。傾向スコアや DR は「交絡が観測共変量 X で説明できる」という仮定のもとでの調整であり、ルールの未観測要素が残ればバイアスが残る [4]。

1.4 課題に対する結果の要約 (先読み)

- ・ **高コンバージョン確度の傾向:** 購入予測モデル (ロジスティック / HGB) と層別要約から、スコア上位層は `history` や紹介経由などのパターンと整合的な特徴を持つ (第 4-11 節)。
- ・ **誰にプロモを送るか:** 期待利益のオフライン代理 (`history` を価値 proxy、`analytics/config.py` のコスト仮定) のもとでは、「No Offer / Web」

等の低コスト側が最頻推奨になりうるシナリオがある（第 10 節）。接触上限がある場合は貪欲割当てで近似（同節）。

- **新施策の方向性**：オフライン上の順位は OOF・ホールドアウトで過信を監視し、パイロット RCT（第 12 節）で増分効果を確認する。上位スコア層に限定した A/B で訴求・コストの組み合わせを探索するのが次の一歩となる。

1.5 本稿の構成と優先順位（データ・手法・結果）

読者が**事前知識なし**でも流れを追えるよう、重要度の高いブロックから次のように並べる。提出前の自己チェックとして、**目次だけを読んでストーリーが通るか**を確認するとよい。

Table 2: 分析ブロック一覧（それぞれ「データ → 手法 → 結果の見どころ」）

順	主なデータ	手法（非専門家向けの言い換え）	結果で確認すること
1	全列の周辺・層別 CVR	分布・棒グラフ・ヒートマップ（記述）	どのオファー／チャンネル層で購入率が高く見えるか（因果ではない）
2	カテゴリ特徴量と購入	独立性検定 + FDR（ 関連のざっくりスクリーニング ）	どの変数が購入と統計的に結びつくか（効果量も見る）
3	recency, history 等	購入予測モデル（ 将来の購入しやすさのランキング ）	ROC/PR・校正・TopK% CVR（ターゲティングの強さ）
4	処置・共変量・結果	傾向スコア + DR（ 観察データでの処置比較の参考値 ）	処置間の水準差・ESS・全件 vs ホールドアウトのギャップ
5	予測確率・コスト仮定	期待利益とオフポリシー評価（ ルールのオフライン試算 ）	推奨処置の分布・フル学習と OOF のずれ
6	潜在表現・クラスタ	次元削減・クラスタ（ 顧客の類型イメージ ）	セグメントの安定性（ARI）と解釈の限界
7	（設計用）	必要サンプル表・倫理・監視（ 実験と運用の枠組み ）	スケール前チェックとモニタ項目

1.6 本稿の貢献（分析パイプラインとしての位置づけ）

- **再現可能なレポート生成**：図表・artifacts/・本 PDF は同一スクリプトから再生成可能。
- **楽観バイアスの可視化**：フル学習評価、 K 折 OOF、ホールドアウト、DR（全件学習 vs ホールドアウト）を並置する。

- **重み付き推定の診断:** 処置別 ESS と傾向スコア分布で IPW 系推定の安定性を監視する。
- **意思決定への接続:** 制約付き配信、A/B 必要サンプル表、ガバナンス・モニタリング表を同梱する。

1.7 記号とデータ生成

表 3 に主要記号をまとめる。以降の数式はこれに従う。

Table 3: 主要記号（本文で統一）	
記号	意味
i	顧客インデックス、 n は標本サイズ
$Y_i \in \{0, 1\}$	購入 (conversion)
T_i	観測された処置 (offer と channel の組)
X_i	共変量ベクトル (recency, history 等)
H_i	売上 proxy (円、フィールド history)
$\hat{e}(t X_i)$	傾向スコアの推定値 (多値ロジスティック)
$\hat{\pi}(t, X_i)$	結果モデルによる $\Pr(Y_i=1 X_i, T=t)$ の推定値
$\hat{\Pi}_i(t)$	期待利益のオフライン代理 (式 (2))
$\hat{\mu}_{\text{DR}}(t)$	処置 t に対する DR 推定量 (式 (1))

1.8 図表の見方と再現性

静止画は `figures/` (EDA・ROC 等) と `figures/improvements/` (診断・政策・サマリー) に保存する。インタラクティブな Plotly 図は `figures_html/*.html` をブラウザで開くと拡大・回転が可能 (PDF には同内容の PNG を併記)。図中の日本語は `analytics/figures_jp.py` で **BIZ UDGothic** (BIZ UD ゴシック) を最優先し、未導入時は Meiryo 等へフォールバックする。本稿では各図を独立した float とキャプションとして掲載する。

1.9 本編と付録の読み方 (役割分担)

本編では、課題に対する結論 (推奨ターゲット・KPI・識別上の注意) と、意思決定に直結する図表 (ROC、政策比較、パイロット規模の目安) を優先して読めるように構成する。付録では、仮定データによるデモ (フェルミ推定・合成ログ)、コード抜粋、中間 CSV の所在、再現コマンドをまとめる。数式・診断の細部は本編に残すが、読み飛ばして付録だけ追うと実装・監査に向く。

2 推奨ターゲットの定義と評価 KPI

課題への直球の答え (1 段落)。ベース特徴 (recency, history, 過去プロモ利用, zip_code, is_referral) のみから推定した購入スコアの上位 5–10% は、

過去購入価値が高く・recency が低い傾向が強い（表 10）。過去割引・BOGO 利用の観察比率など層別のプロファイルは表 5 に集約（スコア定義に依存し、紹介フラグは必ずしも単調に増えない）。誰に何を「スコア層 × オファー × チャンネル」として離散処置で評価するが、本データには**メッセージ文面・接触頻度・配信タイミング**が無い（施策の射程はオファー種別とチャンネルに限定）。オフライン上の期待利益代理ではコスト仮定次第で**無オファー・低コストチャンネル**が支配的になりうるため、「高確度だから重いプロモ」は**増分効果とコスト**を RCT で確認するまで採用しない（第 10 節・図 38）。

Table 4: 評価 KPI の階層（パイロット～本番の合意用。数値は組織で確定）

区分	指標	備考
Primary（短期）	増分購入率（RCT 各臂対ホールドアウト）、増分期待利益 proxy（円）	本稿では H_i =history を売上 proxy。真の粗利は別途。
Primary（効率）	接触（または送客）あたりの増分利益 proxy、オファー原価を含む ROI	接触コストは config.py シナリオ。実コスト連携後に更新。
副次（短期）	オファー別・チャンネル別の CVR、クレーム・返品率（取得できれば）	在庫・品切れ外部性の監視。
副次（長期）	試験終了後 90 日の累積売上 / LTV proxy、90 日以内再購入、チャーン	割引乱発による価格感応の習慣化・ブランド毀損の早期検知。
モデル健全性	AUC-PR、Brier、ECE（10 ビン）、PSI、処置別 ESS	閾値例：第 8 節。ゲート逸脱時は配信縮小。
ガバナンス	センシティブ属性 proxy の利用監査、説明・異議申立て経路	表 8。

送る／送らない（オフライン・運用ルール案）．

- **送る（優先検討）**：購入スコアが上位 5–10 %かつ、オフライン期待利益代理（式 (2)）で当該顧客にとって**最良の処置**がインセンティブ付きでない、または予算・接触上限内で割り当て可能な場合。制約付き配信では貪欲割当の結果に従う（第 10 節）。
- **条件付きで送る**：スコアは中位だが在庫処理・季節キャンペーン等の**ビジネス上の理由**があり、RCT またはホールドアウトで**害がない**ことが確認されているセル。
- **送らない／ホールドアウト**：スコア下位で期待利益代理が負、または同一顧客への**過剰接触**が予想される場合。RCT のコントロール臂として無処置を必ず確保する。
- **禁止**：ガバナンス上レビュー前に、地域カテゴリ等の**禁止・要レビュー変数のみ**を理由に不利益な差別的配信を行わない（第 13 節）。

上位スコア層のプロファイル（記述）．

Table 5: スコア層のプロファイル (過去割引・BOGO・紹介の観察比率。記述)

セグメント	n	used_discount	used_bogo	is_referral
全体	64000	55.1%	55.0%	50.2%
上位 10%	6400	65.6%	90.8%	28.9%
上位 5%	3200	79.8%	97.2%	31.1%

3 問題設定と識別仮定

3.1 潜在的結果とターゲット

処置 $T \in \mathcal{T}$ を (オファー, チャネル) の組とする。潜在的結果 $Y(t)$ 、観測結果は

$$Y_i = \sum_{t \in \mathcal{T}} \mathbf{1}\{T_i = t\} Y_i(t).$$

平均処置効果 $\mathbb{E}[Y(t) - Y(t_0)]$ 等が関心量となるが、観察データでは一般に識別できない。

3.2 識別条件

無視可能性: $Y(t) \perp T \mid X$ (交絡が X に含まれる)。**SUTVA:** 処置の定義が顧客間で干渉しない。**共通支援:** $0 < e(t \mid x) < 1$ (e は真の傾向スコア)。いずれかが崩れると、本稿の DR・OOF 評価は方向を示す参考値にとどまる。傾向スコアによる調整の古典的枠組みは [1] を参照。

3.3 補足：購入しやすさの予測と「増分効果」の違い

機械学習の世界標準的な整理として、「いま買いそうな人」を当てる予測（購入確率のランキング）と、「プロモーションを見せたから買った」という増分（いわゆる uplift / 処置効果の個人差）は、別の問いである。前者が高い人に割引を出すと、もともと買う人にコストだけが乗る——いわゆる無駄な割引——になりやすい。後者を直接見るには、無作為に処置を振る実験や、厳格な準実験・専用モデルが必要になる。本稿の購入予測は主に前者（ターゲティングの優先順位）を担い、DR や期待利益は観察データの範囲で処置間比較の参考に留まる（因果を断定しない）。

4 データと探索（分布・条件付き CVR）

(この節のねらい) `exercise.csv` の各列がどのような形で購入と結びついて見えるかを、グラフと記述 CVR で把握する。ここで得られるのは仮説と特徴量の妥当性であり、オファー間の差は因果効果として読まない。

4.1 周辺分布と層別箱ひげ

図 1-4 に、主要共変量の周辺分布と購入有無別の箱ひげを示す。




Figure 1: recency (最終購入からの月数) の周辺分布




Figure 2: history (過去購入価値 proxy、円) の周辺分布

解釈

周辺分布は接触母集団の代表性と外れ値・右裾を把握するための記述統計である。箱ひげは $\Pr(\text{共変量} | Y)$ の差を示すが、これは**因果効果ではない**。特に recency と処置の割当が相関する場合（例：休眠顧客に強いオファー）、高い条件付き CVR は**交絡**により過大評価されうる。




Figure 3: recency：購入有無別の箱ひげ




Figure 4: history（円）：購入有無別の箱ひげ

4.2 オファー × チャンネル別の条件付き CVR

図 5 はセルごとの標本 CVR を色で表す。セル内件数が小さい組み合わせでは標準誤差が大きい。




Figure 5: オファー × チャンネル別 CVR ヒートマップ（記述統計）

解釈

セル間のコントラストは交互作用の存在の手がかりとなる。ただし各セルの値は $\Pr(Y_i=1 \mid T_i, \text{セル})$ の観察された連関であり、コストを伴う期待利益の最適処置とは一致しない場合がある（後章）。

4.3 属性別 CVR（棒グラフ）

図 6-8 に、オファー・チャンネル・地域の一変量層別 CVR を示す。




Figure 6: オファー別の条件付き CVR




Figure 7: チャンネル別の条件付き CVR




Figure 8: 地域別の条件付き CVR

解釈

棒の差は**セグメント施策の動機**となるが、層の定義が処置と同時に決まる変数（過去プロモ利用など）では**過去の処置**と**現在の割当**が絡み、因果の読み替えに注意する。地域はセンシティブ属性の proxy になりうるため、配信ルールへの直結はガバナンスレビューを前提とする。

5 多重検定（FDR）と効果量

5.1 方法

各カテゴリ特徴量について購入との**独立性のカイ二乗検定**を行い、Benjamini–Hochberg 手順で偽発見率（FDR）を q 値として報告する。効果量には Cramér's V を併記し、 p 値のみに依存しない。




Figure 9: カイ二乗検定に基づく効果量（Cramér's V ）

解釈

大標本では**統計的有意** $\neq$ **実務的に大きな効果**となりやすい。 V が小さい場合は、予測モデルへの寄与も限定的である可能性がある。多数の変数が購入と関連する場合、ロジスティック回帰では**多重共線性**により係数解釈が難しくなる。

補足（特徴量重要度）．カイ二乗は**周辺**の関連スクリーニングに留まる。予測モデル内での寄与を説明するには、本系モデルに対する **SHAP** 値や Permutation importance など、モデル条件付きの分解を併記すると「どの変数がスコアを押し上げたか」の説明が強化される（本稿の主推定はロジスティック／HGB の予測精度と政策接続が主目的）。

6 相関と補助的重回帰 (history)

6.1 Pearson 相関 (数値・二値)

図 10 は主要な数値・二値列の Pearson 相関を下三角のみ表示したものである (重複セルを避ける)。強い相関は特徴設計上の冗長性の手がかりとなるが、因果ではない。




Figure 10: 相関行列 (Pearson、下三角)

6.2 OLS (目的変数を history)

演習で例示される重回帰に対応するため、連続の history を目的変数とした OLS (説明変数は recency, used_discount, used_bogo, is_referral、ロバスト分散 HC1) を付す。購入予測そのものは次節以降のロジスティック回帰が主である。係数表は artifacts/ols_history_coefficients.csv。

7 LSI 類似表現と分類アブレーション

各行を英語テンプレの短文に変換し、訓練標本のみに fit した TF-IDF と TruncatedSVD (次元は artifacts/lasi_tfidi_diag.json) を特徴に連結し、ロジスティック回帰のホールアウト性能を **BASE のみ** と比較する (外




Figure 11: recency と history の散布図 (色は購入有無)




Figure 12: OLS 係数と 95% 信頼区間 (history を目的変数)

部 API 不要)。図 13 は同一分割における AUC / Brier / AP / TopK% CVR の対比である。




Figure 13: BASE vs BASE+TF-IDF+SVD (同一ホールドアウト・値ラベル付き棒)

8 予測モデル (ROC・校正・PR)

(この節のねらい) 顧客ごとに購入しやすさをスコア化し、限られた接触枠で誰を優先するか材料にする。AUC/PRは順位付けの良さ、校正は確率の絶対値の信頼性(期待利益計算に効く)を見る。

8.1 評価指標の意味

AUC (ROC) : 閾値を掃引したときの誤警報率と検出力のトレードオフを要約したランキング指標。**Brier スコア**: 確率予測の二乗誤差。**校正曲線**: 予測確率ビンにおける観測頻度との一致(校正)。**PR 曲線・AP**: 陽性クラスが稀なときの precision-recall トレードオフとその要約。

解釈

AUC が中程度のとき、完全分離は達成されておらず、**ターゲティングの上限**が統計的に制限される。期待利益は確率の**絶対水準**に依存するため、校正の崩れは**政策の順位入れ替え**を招きうる。運用では ECE やドリフト監視が有効である。**閾値例 (運用ゲートのたたき台)** : 10 ビン ECE が訓練時比 **+0.05**を超えたら再校正を検討、**+0.08** 超なら配信縮小 (ホールドアウト比較と併用)。Brier 悪化がベースライン比 **10 % 相対超過**ならモデル差し替え候補とする (組織で合意したうえで固定化する)。




Figure 14: ROC 曲線 (logistic regression、ホールドアウト)




Figure 15: ROC 曲線 (histogram-based gradient boosting、ホールドアウト)




Figure 16: 校正曲線 (logistic regression)




Figure 17: 校正曲線 (HGB)




Figure 18: Precision–Recall 曲線 (logistic regression)




Figure 19: Precision–Recall 曲線 (HGB)

解釈

AP と TopK% CVR (表) は限られた接触枠のもとでの運用品質に直結する。木系が線形より Top 尾で有利な場合があり、ROC の差以上に政策評価に効くことがある。

9 因果推論（傾向スコア、DR、ブートストラップ）

(この節のねらい) 観察されたオファー・チャネル割当のもとで、処置ごとの購入率の参考比較をする。傾向スコアと結果モデルを組み合わせた DR はどちらか一方が少し誤っていても頑健という性質があるが、未観測の交絡があると根本的には残る。

9.1 DR 推定量 (参考)

二重頑健推定の考え方は [2]、方策評価への応用は [3] などを参照。処置 $t \in \mathcal{T}$ について、本実装で用いる DR 形式は次の標本平均である：

$$\hat{\mu}_{\text{DR}}(t) = \frac{1}{n} \sum_{i=1}^n \left\{ \hat{\pi}(t, X_i) + \frac{\mathbf{1}\{T_i = t\}}{\hat{e}(t | X_i)} (Y_i - \hat{\pi}(t, X_i)) \right\}. \quad (1)$$

ここで $\hat{e}$ は多値ロジスティック傾向、 $\hat{\pi}$ は処置を特徴量に含む結果モデル（ロジスティック）から得る。クリップを $\hat{e}$ に施し、極端な IPW 重みを抑制する (PROPSENSITY_CLIP)。

9.2 実装上の注意（同一データ学習）

本パイプラインでは、傾向・結果モデルを同一学習標本上でフィットし、同一標本で式 (1) を評価している。一般にこれはナイーブで楽観的となりうる。厳密にはサンプル分割や cross-fitting により「自分で学習したデータで評価しない」手続きが推奨される。本稿で cross-fitting を最終報告に組み込まない理由は、(i) 演習レポートの実装コストと可読性、(ii) 既存パイプラインがホールドアウト再学習・OOF 政策評価で同種の過信を別経路から監視している、のトレードオフによる（拡張は今後の方針）。本稿ではホールドアウト再学習による棒グラフ比較で、そのギャップの大きさを監視する。

解釈

処置ごとに全件とホールドアウトの差が大きい場合、過学習、傾向の極小確率、または結果モデルの誤指定が疑われる。差が小さくても未観測交絡は残る。

解釈

ESS が低い処置では、少数観測に過度に重みが乗り、DR の分散が増大する。その場合、政策の主役から外す・傾向のトリミング（極端に小さい $\hat{e}$ を持つ




Figure 20: 処置別 DR：全件学習による評価とホールドアウト再学習による評価の比較




Figure 21: 処置別 ESS (IPW 重みに対応する有効標本量の目安)

単位の除外)・**処置セルの集約** (類似オファーをまとめて $|T|$ を縮小)・別母集団での感度分析を検討する。




Figure 22: DR 点推定とブートストラップ区間 (森林図風)

解釈

区間は**部分標本再学習**に基づく。処置間で区間が重なるとき、**順位確定**には実験が有効である。

9.3 層別の観察差と「無駄割引」仮説への接続 (参考)

観察データのみでは処置の増分効果 (uplift) は識別できないが、購入スコアを層別化したうえで**観察されたオファー間の CVR 差を眺めることは仮説生成**には有用である。第 15.5 節の図 38 は、スコア十分位ごとに「Discount」と「No Offer」の観察 CVR 差を示す (割当交絡あり)。高スコア側で差が相対的に小さい場合は、もともと購入確率が高い層では割引の**辺際の上乗せ**が小さい可能性を想起させる——いわゆる**無駄割引問題**だが、確証は RCT が要る [5, 6]。

10 期待利益・オフポリシー評価・ベンチマーク

(この節のねらい) 購入確率だけでなく**粗利 proxy**と**コスト仮定**を合成し、どの処置を誰に送ると**オフライン上もっとも良さそうか**を離散政策として評価する。フル学習と OOF の差は**過信 (楽観バイアス)**の目安になる。オフポリシー評価・方策学習の理論的整理は [3]、オンライン実験の実務は [5] を参照。

10.1 期待利益の定義 (オフライン代理)

顧客 i 、処置 t について、本稿で用いる期待利益の代理は

$$\hat{\Pi}_i(t) = \hat{\pi}(t, X_i) H_i - c_{\text{off}}(t) H_i - c_{\text{ch}}(t) H_i. \quad (2)$$

ここで $c_{\text{off}}(t)$ 、 $c_{\text{ch}}(t)$ はシナリオ依存のコスト係数 (DEFAULT_SCENARIOS)。離散処置について $\arg \max_{t \in T} \hat{\Pi}_i(t)$ を個別最適政策とみなす。

コスト仮定の感度 (推奨処置の入れ替わり) . analytics/config.py の low_cost / mid_cost / high_cost は係数が異なるが、現行の $\hat{\pi}$ のもとでは**最頻推奨がすべて同一になる**場合がある (コスト項の差が離散最適を変えない)。そこで artifacts/profit_long.csv に記録された処置別購入確率と history を固定し、**より幅の広い係数パターン**で期待利益を再計算した結果を表 6 に示す。極端な設定同士では顧客ごとの最適処置が**大きく不一致**になりうる——すなわち、**コスト見積りが政策の結論を左右しうる**ことを示す (あくまでオフライン・参考)。

Table 6: コストシナリオ別の最頻推奨処置 (profit_long.csv の $p \cdot \text{history}$ を固定し、係数のみ変更して再計算。参考)

シナリオ (概略)	最頻推奨 (処置)	割合
extreme_lean (割引係数小)	Discount / Web	86.1%
low_cost (config 相当・やや控えめ)	No Offer / Web	96.3%
mid_cost	No Offer / Web	100.0%
high_cost	No Offer / Web	100.0%
extreme_heavy (割引係数大)	No Offer / Web	100.0%

極端設定間 (extreme_lean vs extreme_heavy) で**同一の離散処置**が選ばれた顧客の割合：**13.9%** (残りは処置が不一致＝コスト仮定で結論が入れ替わる)。

10.2 オフポリシー評価の読み方

フル学習: 全データで学習した $\hat{\pi}$ で評価 (楽観バイアスがありうる)。**OOF**: K 折で学習していないフォールドの予測を用いる。**ホールドアウト**: 保持検証セット上の予測を用いる。




Figure 23: 推奨処置の分布 (シナリオ別)




Figure 24: フル学習 vs OOF 期待利益（顧客ごと）




Figure 25: ベンチマーク政策の比較




Figure 26: シナリオ別 期待利益要約

解釈

推奨分布の集中（例：一処置に 100%）は、コスト仮定のもとで他処置が**支配的に不利なことのシグナル**であるが、モデル誤差でも起こりうるため散布図と OOF を併読する。ベンチマーク棒は**単純ルールで十分**かの基準線を与える。

意思決定フロー（例）




Figure 27: 意思決定フロー（ゲート例）

解釈

図 27 は**オフライン合格** → **パイロット** → **スケール**の例。図 28 でフルだけ突出していれば、**過信**の警告となる。

10.3 制約付き配信（貪欲近似）

接触上限・予算等の**整数制約**下では、全員への $\arg \max_t$ は実行不可能な場合がある。実装では貪欲割当により**近似解**を求める。一般に**最適解との最適性ギャップ**は問題依存である。




Figure 28: 評価モード別 平均期待利益




Figure 29: 制約付き配信：選択割合の変化（例）

解釈

図は**運用イメージ**であり、実予算・キャパに合わせパラメータを再設定する。
完全最適が必要な場合は MIP 等との比較が望ましい。

11 セグメントと頑健性

(この節のねらい) 顧客を類似した群に分け、施策メッセージや検証単位のイメージを掴む。クラスタの安定性 (ARI) が低いときは、セグメント固定ルール of 再現性に注意する。

11.1 潜在空間の可視化

PCA は線形、UMAP は非線形構造を強調するが、**大域的距離の厳密解釈は持たない**。クラスタリングは主に UMAP 座標上で実施し、**ARI** でシード頑健性を確認する。




Figure 30: 潜在空間：PCA 2D (購入で色分け)

解釈

セグメントラベルは**説明用**であり、差別的利用やセンシティブ属性の proxy 化には**人のレビュー**を要する。HTML 版は `figures_html/` を参照。




Figure 31: 潜在空間：UMAP 2D




Figure 32: 潜在空間：UMAP 3D (PNG 静止画)

潜在空間 (3D) : UMAP (色=KMeansセグメント)
 全母集団 $n=64,000$ / 表示点 $n=8,000$ (ランダム) ・色はクラスID




Figure 33: 潜在空間：セグメント着色 (UMAP 3D)




Figure 34: クラスタ数 k とシルエット係数




Figure 35: 多シードに対するクラスタ安定性（ARI）

解釈

ARI が低い場合、セグメント施策の固定化は**再現性リスク**を伴う。スコア層への回帰や合意クラスタを検討する。

11.2 セグメント × 処置の観測 CVR（探索）

図 36 は UMAP セグメントと処置（オファー × チャネル）の組み合わせにおける**観測 CVR**を示す。交絡があるため因果効果の読み替えはできない（記述のみ）。詳細は `artifacts/segment_treatment_cvr_exploratory.csv`。

解釈

棒はクラスタ内平均であり、**クラスタ人数**と併読する。小クラスタは偶然の振れが大きい。

12 実験計画（RCT/A/B）

主アウトカムを購入率と置き、有意水準・検定力・最小検出効果（MDE）に基づく必要サンプルは表 7。設計の実務的ガイドは [5]、大規模場における増分計測の比較議論は [6] が参考になる。




Figure 36: 探索的ヒートマップ：セグメント × 処置の観測 CVR




Figure 37: セグメント別 平均期待利益（参考）

Table 7: A/B 必要サンプル（二標本比例・正規近似）

MDE	検定力	片群 n (近似)	合計 n (近似)
0.005	0.8	79742	159483
0.005	0.9	106751	213501
0.010	0.8	20209	40418
0.010	0.9	27054	54107
0.015	0.8	9103	18205
0.015	0.9	12185	24370
0.020	0.8	5187	10374
0.020	0.9	6944	13887

解釈

表の n は**近似の出発点**である。無効検査、多重主アウトカム、クラスターランダム化等で設計を調整する。オフラインで有効に見えた政策が実験で再現しない場合、**実装差・SUTVA・残存交絡**を疑う。

13 ガバナンス・倫理・人の関与

目的限定と最小化 分析目的に必要な列のみを用い、保存期間・アクセス権は社内規程に従う（詳細は `data_dictionary.md`）。

説明可能性と人の関与 セグメント別施策はモデル出力に基づくが、最終配信判断には担当者レビューを置く。自動化された決定のみで不利益を生じさせない運用を推奨。

差別・不利益リスク 地域（`zip_code` 等）などのプロキシ特性に依存する政策は、属性に基づく不当な差別に繋がらないよう設計・監査する。

オプトアウト・問い合わせ マーケティング配信の拒否・個人情報の開示等の請求手続きは、社内ポリシーおよび個人情報保護法（日本）の枠組みに従う。

法的助言ではない 本稿・生成テンプレは**法的助言を構成しない**。実装・運用前に法務・DPO と整合を取ること。

14 運用モニタリングとインシデント対応

解釈

閾値は組織で合意し、逸脱時の**縮小運用・再学習・ロールバック**を手順化する。

Table 8: 配信ルール上の変数区分（コンプライアンス用チェックリスト例）

区分	例と扱い
原則禁止（単独理由での不利益配信）	人種・宗教・健康・性的指向等のセンシティブ属性、その直接の推定値。本演習データには含まれないが、実データ導入時は列レベルで排除。
要レビュー（proxy・相関）	zip_code（都市／郊外／農村など）や地域に強く関連する行動特徴。マーケティング目的に 限定利用 し、説明責任・異議申立て経路を用意。人間による承認ゲートを推奨。
業務上許容（説明可能性の確保）	recency, history, 過去オファー利用フラグ、紹介フラグ等。モデルカードに利用目的・リスクを記載。

Table 9: 監視指標の例（詳細は artifacts/monitoring_spec.*）

領域	監視例
校正	Brier / ECE 週次
ドリフト	PSI / KS
傾向スコア	ESS・極小 e 割合

15 まとめと今後の方針

ゴールへの3行（課題の問い：誰にプロモを打つか）。(1) 購入確度が高い層は、予測スコア上位に history や紹介などのパターンが現れやすい。(2) オフライン期待利益では **インセンティブを掛けない接触（例：No Offer / Web）**が主軸になりうる——「高確度だから割引」は必ずしも最適ではない。(3) 次は **上位スコア層を母集団にしたパイロット実験**で、購入率・利益 proxy (円)・コストを検証する（表 7 の母数は出発点）。

15.1 最終課題の再確認

課題は、店舗顧客データに基づき **コンバージョン確度の高いユーザーの傾向**を捉え、**プロモーションを打つべき顧客層**を検討し、**新施策**につなげることであった。本稿ではこれに答えるため、(1) exercise.csv に対する EDA と購入予測、(2) 処置別の参考推定と期待利益、(3) 実験・ガバナンスまでを一連の流れとして整理した。

15.2 分析結果の要約

- ・ **傾向**：条件付き CVR・予測モデル・セグメント要約から、購入しやすい層は history や紹介などの信号と整合的なパターンを示す（ただし交絡あり）。
- ・ **ターゲティング**：スコア上位（Top K%）は実測 CVR がベースレートを上回り、**接触枠の配分**には使える。

- **政策**: 期待利益のオフライン代理では、コスト仮定によっては**無オファー・Web 等が支配的**になりうる。オフライン合格後は RCT で増分効果を確認するのが筋である。

15.3 想定や直感と異なる結果とその理由

課題の字面だけでは「購入確度が高い人にプロモを打つ」ことが最適に読めるが、本データと目的関数では次のように**読み替え**が必要である。

- **購入しそうな人への割引は利益が出にくい**: 購入確率が高くても、インセンティブコストを引くと期待利益は低くなりうる（**増分性**は別問題だが、期待利益最大化はその方向を示す）。
- **記述 CVR が高いオファーが全体最適とは限らない**: 観察された割当のもとでの条件付き頻度であり、かつコスト項で逆転しうる。
- **オフライン最適は過信しうる**: 同一データで学習したモデルでの評価は楽観的になりやすい。OOF・ホールドアウト・ESS で様子を見る。

15.4 今後の方針（新施策の提案）

- **パイロット設計**: 上位スコア層（例: Top 5–10%）を母集団に、**低コスト訴求 vs 現行オファー vs ホールドアウト**の二因子程度から開始し、購入率・利益 proxy・接触コストを同時に見る（第 12 節のサンプルは出発点）。
- **副次アウトカム**: 試験終了後 **90 日**の累積売上（または LTV proxy）と **90 日以内再購入**を事前登録し、短期 CVR 改善が長期価値を損なわないか監視する（表 4）。
- **運用ゲート**: 校正ドリフト・PSI・ESS・OOF とのギャップが閾値を超えたら配信縮小（ガバナンスおよび運用モニタリングの各節の表を参照）。
- **分析拡張**: cross-fitting による DR、**uplift**（**処置効果の個別差**）推定、制約付き政策の最適性ギャップ評価、長期 LTV データとの接続。

15.5 上位スコア層を母集団としたパイロットの記述（演習データ）

「今後の方針」で述べた **Top 5–10%**の母集団イメージを、`exercise.csv` 上で**記述**として補う。ここでは `recency, history, used_discount, used_bogo, is_referral, zip_code` のみから勾配法で近似したロジスティック風スコアを用い、上位 10%・5% のコホートを定義した（再現: `python scripts/pilot_design_stdlib.py`。sklearn 環境では `python -m analytics.pilot_design_analysis`）。表 10 はコホート規模と観察 CVR、表 11 は**上位 10% 内**のオファー別の観察 CVR である。後者は**割当が無作為でない**ため因果比較には使えず、パイロット RCT（第 12 節）で**低コスト訴求・現行オファー・ホールドアウト**を無作為に割り当てたうえでの増分効果を見る必要がある。表 12 は、上位 10% コホートの

観察 CVR をベースラインとした場合の**仮定 MDE** に対する片群必要人数の目安である（二比例・ $\alpha = 0.05$ ・正規近似。3 臂設計では合計人数はおおむね 3 倍程度のオーダー）。

Table 10: パイロット候補の記述 (recency, history, used_discount, used_bogo, is_referral, zip_code のみから勾配ロジスティックでスコア化し上位%で定義。演習用)

セグメント	n	CVR	mean(history)	mean(recency)
全体	64000	0.1468	242.09	5.76
上位 10%	6400	0.2500	515.85	2.75
上位 5%	3200	0.2678	599.14	2.53

Table 11: 上位 10% コホート内の観察オファー別 CVR (割当交絡あり・記述)

offer	n	CVR
Discount	2172	0.2983
Buy One Get One	2100	0.2476
No Offer	2128	0.2030

Table 12: 仮定 MDE (絶対差) に対する片群必要人数の目安 (ベースライン CVR=25.00%、上位 10% コホート。二比例・ $\alpha=0.05$ ・正規近似)

MDE (絶対差)	検定力	片群 n (近似)	3 臂合計 n 目安
0.010	0.8	29821	89463
0.010	0.9	39921	119763
0.020	0.8	7550	22650
0.020	0.9	10107	30321

15.6 追加で欲しいデータ (次の分析のため)

- ・ 真の粗利・オファー別コスト・接触コスト (会計・オペレーション連携)。
- ・ 割当ルール・露出口グ (誰がなぜそのオファーを見たかの監査証跡)。
- ・ 在庫・供給・クレーム (SUTVA 違反・ネガティブ外部性の評価)。
- ・ 複数期パネル (慣習化・疲労・LTV)。

一般論 (なぜこれらが要るか) : オフラインの期待利益最大化を事業の損益に接続するには、売上だけでなく**返品・原価・オファー毎の変動費と接触・配信の辺際コスト**が揃っていることが望ましい (proxy 感度分析の限界を縮める)。割当の決定規則と**露出・配信ログ** (誰がいつどのクリエイティブ/オファー




Figure 38: 購入スコア（本スクリプトの6次元ロジスティック）十分位ごとの観察 CVR 差（Discount – No Offer）。割当は無作為ではないため真の増分（uplift）ではない。高スコア側で差が相対的に小さい層がありうる——無駄割引仮説の動機付けとして参照し、RCT で検証する。

を見たか）は、観察データでの交絡の説明・監査に加え、RCT・ホールドアウト・ジオテスト等の増分（インクリメンタル）効果の推定において標準的な前提データである（無作為化のない記述比較だけでは処置効果に置き換えられない）。在庫・キャパシティ・クレーム・品切れは、プロモが他者の購入可能性やオペレーションに与える外部性を評価するのに必要で、単一期間の購入有無だけでは SUTVA 違反が見えにくい。複数期の顧客 × 時点データは、同一顧客への繰り返し接触による疲労や価格感応の慣習化、および LTV・チャーンとのトレードオフを分離するために不可欠である（短期 CVR の改善が長期価値を損なわないかの検証）。

数値仮定（フェルミ）．history を円建ての年間購買額プロキシとし、粗利率 0.32 ($\sqrt{0.25 \times 0.40} \approx 0.32$ のオーダー)、キャンペーン 1 回の売上をその 0.083 倍（月次花卉相当・円）、割引・BOGO の売上に対する負担をそれぞれ 25 接触コストは Web/Multichannel/Phone で床 5.0/29.0/92.0 円に加え history の 0.6 平均 history 242.1 円の顧客が 1 回購入した場合の売上目安は 20.17 円、粗利（プロモ前）は 6.46 円。露出は期間中 Poisson($\lambda = 3.2$) の合成ログ、在庫は需要 CV 0.18 ・BOGO 需要 $\times 1.35$ のショック、クレームはベース 1.5

15.7 本稿の位置づけ（ロードマップ）

オフライン評価は識別仮定とコスト・価値 proxy に依存する。本稿の数値はパイロット実験と本番モニタリングを前提にスケールすべきである。

長期・ブランド・インセンティブ疲労．本分析の提案はオフライン上の期待

利益 proxy の最大化にフォーカスする。割引の乱発によるブランド毀損・価格感応度の習慣化・長期 LTV の低下は、本データに直接は含まれないため、別途パネルデータやブランド調査で監視することが望ましい。

公平性・地域属性. zip_code 等の地域カテゴリは差別的配信やセンシティブ属性の proxy になりうる。地域属性のみを理由とした不利益な差別的取り扱いにならないよう、ガバナンス上のレビューと利用目的の限定を前提とする（本文の倫理表と併せて運用する）。

15.8 最終課題への適合性と改善余地（自己査読）

課題文との対応。「購入確度の高いユーザーの傾向」については、EDA・予測モデル・セグメント記述および表 10・表 5 で層別の記述を示している。「その層にプロモを打つ」については、スコア上位の記述 CVR とターゲティング方針に加え、コストを入れた期待利益 proxy と制約付き割当まで踏み込んでいる。「新施策」については、パイロット RCT・運用ゲート・監視・付録の仮定ベース感度が整理されている。よって要件の骨格は満たす。

世界標準の実務・研究から見た強み. 問題設定が増分性 (uplift) とオフライン方針評価のギャップを明示している点、多値介入に DR + OOF を接続している点、倫理・モニタリング・実験計画まで一貫通貫している点は、産業界の「MLOps + 因果」の良い型に近い。

残る改善余地.

- 簡潔さ：診断図の一部を付録へ移し、本編を「結論・識別・主要 KPI」に絞ると、授業レポートとしてさらに読みやすい。
- 本番データ接続：真の粗利・接触コスト・割当ログが揃えば、オフライン政策と P&L のギャップをさらに縮小できる。

References

- [1] Paul R. Rosenbaum and Donald B. Rubin. The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1):41–55, 1983.
- [2] Heejung Bang and James M. Robins. Doubly robust estimation in missing data and causal inference models. *Biometrics*, 61(4):962–973, 2005.
- [3] Miroslav Dudík, John Langford, and Lihong Li. Doubly robust policy evaluation and learning. In *Proceedings of ICML*, 2011.
- [4] Guido W. Imbens and Donald B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press, 2015.

- [5] Ron Kohavi, Diane Tang, and Ya Xu. *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge University Press, 2020.
- [6] Brett R. Gordon, Florian Zettelmeyer, Neha Bhargava, and Dan Chap-sky. A comparison of approaches to advertising measurement: Evidence from big field experiments at Facebook. *Marketing Science*, 38(2):193–225, 2019.

付録の位置づけ

付録は再現手順、中間成果物の所在、および仮定ベースの補完分析(exercise.csv に無い要素のデモ)をまとめる。本編の結論を変える主張は行わず、感度・監査・実装のための材料として利用する。

A 限界と免責

- 観察データ: 未観測交絡、SUTVA 違反、慣習化 (risk_register.json 参照)。
- ブートストラップ: 部分標本再学習であり、厳密な頑健区間の代替ではない。
- 法的助言: 本稿は法的・コンプライアンス上の助言を構成しない。

B 付録：データスニペットの再現方法

表 1 とデータ概要の簡条書きは、リポジトリ直下の exercise.csv から python -S scripts/build_latex_data_snippets.py (または通常の python) で latex/data_overview_snippet.tex と latex/data_sample_table.tex を再生成できる。

C 付録：コスト感度表の再現方法

表 6 は artifacts/profit_long.csv から python -S scripts/build_cost_sensitivity_from_profit.py で再生成できる。

D 付録：本文で詳述しきれなかった出力物

詳細な数表・中間成果物は artifacts/ に集約する (例: chi2_tests_with_fdr.csv、promo_targets*.csv、policy_eval_compare.csv、segment_treatment_cvr_exploratory.csv)。Markdown 版の長い考察は final_report.md を参照。

E 付録：仮定データによる補完分析（図表・サンプル・コード）

`exercise.csv` には粗利・真の接触コスト・露出ログ・在庫・複数期パネルが含まれない。本節では、**フェルミ推定**でオーダーを揃えた**仮定**(`artifacts/assumed_data_fermi.json`)のもとで会計風の利益分解・合成露出・在庫モンテカルロ・疲労付き合成 LTV を**デモ**として付す。解釈はすべて**演習上の感度・監査イメージ**であり、事業数値の断定や因果効果の主張ではない。

接触コスト（円）のフェルミ推定. Web. 一斉メール等の限界費用を 0.5–2.0 円/通、ESP・創出の按分を 2–10 円/接触の帯とし、オーダーを足し合わせて床を **5 円**とした（限界費用帯と按分帯の幾何平均を合成し、最低 **5 円**でキャップ）。

Multichannel. Web 床に SMS/プッシュ等の追加分 18–30 円の中央（24 円）を加え、床 **29 円**。

Phone. 架電オペの時給負担（人件費・諸掛）を 2000–2800 円/時、実効接触を 20–32 件/時と置き、中央 $2400/26.0 \approx 92.3$ 円/接触 → 床 **92 円**。

history 比例項. 年間購買額プロキシに対する変動オペ・差し替え負担を 0.4

E.1 仮定パラメータ（JSON）

パラメータの機械可読な一覧は `artifacts/assumed_data_fermi.json`(`python -m analytics.assumed_supplementary_analysis` で再生成)。本文の数値は円建て `history` との整合を前提とする。

E.2 データセット抜粋（演習用 `exercise.csv`）

全件はリポジトリ直下の `exercise.csv`。先頭 500 行は `artifacts/appendix_exercise_sample.csv`。以下は**先頭 12 行のみ**（全列）。

Listing 1: `appendix_exercise_sample.csv` 先頭 12 行

```
1 customer_id,recency,history,used_discount,used_bogo,zip_code,is_referral,channel,offer,conversion
  0,10,142.44,1,0,Surburban,0,Phone,Buy One Get One,0
  1,6,329.08,1,1,Rural,1,Web,No Offer,0
  2,7,180.65,0,1,Surburban,1,Web,Buy One Get One,0
  3,9,675.83,1,0,Rural,1,Web,Discount,0
6 4,2,45.34,1,0,Urban,0,Web,Buy One Get One,0
  5,6,134.83,0,1,Surburban,0,Phone,Buy One Get One,1
  6,9,280.2,1,0,Surburban,1,Phone,Buy One Get One,0
  7,9,46.42,0,1,Urban,0,Phone,Buy One Get One,0
  8,9,675.07,1,1,Rural,1,Phone,Discount,0
11 9,10,32.84,0,1,Urban,1,Web,Buy One Get One,0
  10,7,548.91,0,1,Urban,1,Phone,Buy One Get One,1
```




Figure 39: フェルミ仮定のオーダー（粗利・売上スケール・オファー負担・接触・露出）。




Figure 40: 仮定会計（粗利－プロモ－接触）下での観察オファー別の平均利益。因果効果ではない。




Figure 41: 同・仮定会計での利益分布（バイオリン）。




Figure 42: チャンネル別の接触コスト曲線（床＋ history 比例）。




Figure 43: 合成露出ログ：監査スコアとインプレッション数。




Figure 44: 合成インプレッション数のビン別・観察 CVR (記述。因果の主張はしない)。




Figure 45: 合成割当と観察オファーのクロス（交絡のイメージ）。




Figure 46: 需要ショックに対する欠品確率（モンテカルロ）。




Figure 47: オファー別クレーム率のフェルミ仮定。




Figure 48: 合成パネルにおける LTV と累積接触（疲労）。

E.3 合成露出ログ抜粋

Listing 2: synthetic_exposure_log_sample.csv 先頭 10 行

```
customer_id,impressions,score_audit,p_discount_propensity,synthetic_assigned_offer,observed_offer
0,3,0.6970679669930135,0.5367008653706069,No Offer,Buy One Get One
3 1,5,1.3116010945759211,0.6817012477705361,Buy One Get One,No Offer
2,5,0.9183182034818489,0.5910525346803097,No Offer,Buy One Get One
3,4,2.3859931255234135,0.8624741319137733,Buy One Get One,Discount
4,3,0.1873764037966622,0.4103246159754508,Discount,Buy One Get One
5,3,0.5587423288612844,0.5021855682953972,No Offer,Buy One Get One
8 6,0,1.259982760119646,0.670397350414328,No Offer,Buy One Get One
7,2,0.394616879817109,0.4612321891427278,No Offer,Buy One Get One
8,0,2.3838300744966796,0.862217365798505,Discount,Discount
```

E.4 分析に用いた Python コード

全文は analytics/assumed_supplementary_analysis.py。再現は `python -m analytics.assumed_supplementary_analysis`。以下はモジュール先頭と FermiAssumptions 定義部の抜粋（円建て history のコメント含む）。

Listing 3: assumed_supplementary_analysis.py 抜粋（先頭 58 行・FermiAssumptions 途中まで）

```
"""
追加で欲しいデータ（粗利・接触コスト・露出・在庫・パネル等）に対し、
フェルミ推定ベースの仮定を置いて補完分析・図表を生成する。

5 出力:
- artifacts/assumed_data_fermi.json
- artifacts/assumed_economics_by_row.csv（サンプル用に最大5万行）
- artifacts/appendix_exercise_sample.csv
- artifacts/synthetic_exposure_log_sample.csv
10 - artifacts/synthetic_panel_ltv.csv
- figures/appendix/*.png
- latex/appendix_assumed_supplementary.tex（図の includegraphics ブロック）
- latex/appendix_fermi_numeric_snippet.tex（本文用の数値1段落）
- latex/appendix_contact_cost_fermi.tex（接触コスト床のフェルミ推定の根拠）

15 再現: python -m analytics.assumed_supplementary_analysis
"""
from __future__ import annotations

20 import json
import math
from dataclasses import asdict, dataclass
from pathlib import Path
from typing import Any, Dict, Tuple

25 import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
```

```

30 from analytics.config import ART_DIR, DATA_PATH, ROOT
    from analytics.figures_jp import save_fig, set_japanese_font

    FIG_APPENDIX = ROOT / "figures" / "appendix"
    LATEX_DIR = ROOT / "latex"
35

def estimate_jpy_contact_costs_fermi() -> Tuple[Dict[str, Any], Dict[str,
    float]]:
    """
    チャンネル別接触コスト（円）の床と history 比例項をフェルミ推定する。
40
    Web: 一斉メール等の限界費用は通数あたり約 0.3--2 円。ESP・創出の固定費按分を
    粗く 2--8 円/接触とみなし、幾何平均  $\sqrt{(1 \times 12)} \approx 3.5$  に丸めて保守的に 5
    円を床とする。

    Multichannel: Web 接触に SMS/プッシュ等を足す。SMS 辺際 3--12
    円/通のオーダーで
45 追加 20--35 円  $\rightarrow$  Web 床 +27 円  $\approx$  32 円。

    Phone: 架電オペの時給負担（人件費+社保+場所+システム）を 2,000--2,800 円/時、
    実効接触（リストアウト除く）20--32 件/時と置く。中央  $2,400/27 \approx 89 \rightarrow 90$ 
    円/接触。

50 history 比例項:
    高額客の優先ルーティング・短いスクリプト差し替え等を年間購買額の
    0.4--0.8% とし 0.006 (0.6%) を採用。
    """
    # Web 床（円）: 限界費用帯と按分帯の幾何平均のオーダー  $\rightarrow$  5 円
    marginal_lo, marginal_hi = 0.5, 2.0
55 alloc_lo, alloc_hi = 2.0, 10.0
    floor_web = round(math.sqrt(marginal_lo * marginal_hi) +
        math.sqrt(alloc_lo * alloc_hi) / 2)
    floor_web = float(max(5.0, floor_web))

```




Figure 49: 仮定会計におけるオffer別の平均内訳 (売上・COGS・プロモ・接触・粗利)。